Міністерство освіти і науки України

Національний університет «Львівська політехніка»

Кафедра систем штучного інтелекту



ЗВІТ

до Лабораторної роботи № 3

з дисципліни «Інтелектуальний аналіз та візуалізація даних»

*на тему: «**Діагностика шкал вимірювання**»*

Виконала:
студентка групи ШІ-32
Хвостова Олександра

Лектор: Виклюк Я. І.
Прийняла: Торська Р. В.

Львів – 2026

Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx`, `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

In [1]:
```
ПРІЗВИЩЕ_ІМЯ = 'Хвостова Олександра'
ГРУПА        = 'ШІ-32'
НОМЕР        = 12

assert ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

In [2]:
```
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', 60)

ВАРІАНТИ = json.load(open('lr3_variants_student.json', encoding='utf-8'))
В = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {В["варіант"]}   ·   {ПРІЗВИЩЕ_ІМЯ}   ·   {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(В['стовпці'], 1):
    print(f'   {i}. {c}')
print()
print('Ваша пара для аналізу зв’язку:', ' та '.join(В['пара']))
print()
print('Ваше додаткове питання:')
print('  ', В['питання'])
```

```
================================================================================
ВАРІАНТ 12   ·   Хвостова Олександра   ·   ШІ-32
================================================================================

Ваші вісім стовпців:
   1. Телефон
   2. Примітка
   3. ступінь КТ
   4. Виписка
   5. spO2 випис
   6. АТ стац
   7. Д-дим2
   8. Гемогл2

Ваша пара для аналізу зв’язку: ЛН та помер/жив

Ваше додаткове питання:
   Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте т
ри способи перетворити його на числові ознаки та обґрунтуйте, який із них
візьмете в модель.
```

In [3]:
```
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = В['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

Out[3]:

	Телефон	Примітка	ступінь КТ	Виписка	spO2 випис	АТ стац	Д-дим2	Гем
0	0958469788 дружина Ганна	NaN	сердній	2022-03-10 00:00:00	NaN	150/100	NaN	
1	0671778486, 0994887663 дружина Оксана	отримував актемра, часті носові кровотечі, втрата нюху	середній	2022-03-16 00:00:00	95	130/80	744	
2	0958768045, чоловік Степан 0951784726	часта втрата свідомості в стаціонарі	критичний	2022-01-18 00:00:00	93	140/90	NaN	
3	0959819331. дочка Валентина 0960845205	панкреонекроз	критичний	2022-01-13 00:00:00	93	150/100	NaN	
4	0952294866, дочка Дарина 0678360161	NaN	NaN	2022-03-11 00:00:00	93	130/90	NaN	
5	0959922983 сестра Софія	NaN	середній	2021-12-26 00:00:00	NaN	170/100	NaN	
6	0998073702, дружина Наталія 0998382226	глюкозурія, кетонові тіла в сечі, ЦД, фібриляція передс	важкий	2022-05-11 00:00:00	96	130/80	NaN	
7	0637258771, син Сергій 0968413301	NaN	легкий	2022-05-28 00:00:00	94	120/80	1370	

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність

Шкала	Ознака
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

In [4]:
```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column      Non-Null Count  Dtype 
---  ------      --------------  ----- 
 0   Телефон     120 non-null    object
 1   Примітка    45 non-null     str   
 2   ступінь КТ  42 non-null     str   
 3   Виписка     120 non-null    object
 4   spO2 випис  68 non-null     object
 5   АТ стац     120 non-null    str   
 6   Д-дим2      30 non-null     object
 7   Гемогл2     105 non-null    object
dtypes: object(5), str(3)
memory usage: 13.5+ KB
```

In [5]:
```
# Далі — що є всередині насправді
for c in МОЇ:
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in з.map(type).value_co
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних {з.nunique()
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- Телефон
    непорожніх 120 з 121 | унікальних 120 | типи: str×97, int×23
    приклади: ["'0958469788 дружина Ганна'", "'0671778486, 0994887663 друж
ина Оксана'", "'0958768045, чоловік Степан 0951784726'", "'0959819331. доч
ка Валентина 0960845205'"]

--- Примітка
    непорожніх 45 з 121 | унікальних 44 | типи: str×45
    приклади: ["'отримував актемра, часті носові кровотечі, втрата нюху'",
"'часта втрата свідомості в стаціонарі'", "'панкреонекроз'", "'глюкозурія,
кетонові тіла в сечі, ЦД, фібриляція передс'"]

--- ступінь КТ
    непорожніх 42 з 121 | унікальних 12 | типи: str×42
    приклади: ["'сердній'", "'середній'", "'критичний'", "'важкий'"]

--- Виписка
    непорожніх 120 з 121 | унікальних 90 | типи: datetime×118, str×2
    приклади: ['datetime.datetime(2022, 3, 10, 0, 0)', 'datetime.datetime
(2022, 3, 16, 0, 0)', 'datetime.datetime(2022, 1, 18, 0, 0)', 'datetime.da
tetime(2022, 1, 13, 0, 0)']

--- spO2 випис
    непорожніх 68 з 121 | унікальних 11 | типи: int×66, str×2
    приклади: ['95', '93', '96', '94']

--- АТ стац
    непорожніх 120 з 121 | унікальних 21 | типи: str×120
    приклади: ["'150/100'", "'130/80'", "'140/90'", "'130/90'"]

--- Д-дим2
    непорожніх 30 з 121 | унікальних 30 | типи: int×21, float×8, str×1
    приклади: ['744', '1370', '276', '0.9']

--- Гемогл2
    непорожніх 105 з 121 | унікальних 60 | типи: int×104, str×1
    приклади: ['144', '137', '105', '116']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

In [6]:
```python
ПАСПОРТ = {
    'Телефон':    ('ідентифікатор', 'Номери телефонів родичів із примітко
    'Примітка':   ('номінальна', 'Вільний текст лікаря: значення можна ли
    'ступінь КТ': ('порядкова', 'Ступені від легкого до критичного мають
    'Виписка':    ('інтервальна', 'Календарна дата: різниця між датами ма
    'spO2 випис': ('відношень', 'Сатурація у відсотках має природний нуль
    'АТ стац':    ('відношень', 'Систолічний і діастолічний тиск у мм рт.
    'Д-дим2':     ('відношень', 'Концентрація Д-димеру має природний нуль
    'Гемогл2':    ('відношень', 'Концентрація гемоглобіну в г/л має приро
}

for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))
```

```
паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
pd.set_option('display.max_colwidth', None)
паспорт_df
```

Out[6]:

	Стовпець	Шкала	Обґрунтування
0	Телефон	ідентифікатор	Номери телефонів родичів із приміткою про родинний зв’язок лише ідентифікують контакт і не є величиною.
1	Примітка	номінальна	Вільний текст лікаря: значення можна лише порівняти на рівність, порядку й відстаней між ними немає.
2	ступінь КТ	порядкова	Ступені від легкого до критичного мають природний порядок, але відстані між сусідніми ступенями невідомі.
3	Виписка	інтервальна	Календарна дата: різниця між датами має сенс, а нуль відліку умовний.
4	spO2 випис	відношень	Сатурація у відсотках має природний нуль, тому відношення значень мають сенс.
5	АТ стац	відношень	Систолічний і діастолічний тиск у мм рт. ст. мають природний нуль; у клітинці записано два значення через «/».
6	Д-дим2	відношень	Концентрація Д-димеру має природний нуль, тому відношення значень мають сенс.
7	Гемогл2	відношень	Концентрація гемоглобіну в г/л має природний нуль, тому відношення значень мають сенс.

In [7]:
```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for c in МОЇ:
    ш, об = ПАСПОРТ[c]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{c}: шкалу «{ш}» не розпізна
    assert len(об.strip()) >= 25, f'{c}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрун
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення

- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

In [8]:
```
ПОРЯДОК_КТ = ['легкий', 'середній', 'важкий', 'вкрай важкий', 'критичний'

def очистити_кт(х):
    х = str(х).strip().lower()
    if х.startswith('легк'):
        return 'легкий'
    if х.startswith('серед') or х.startswith('серд'):
        return 'середній'
    return х

def числа(стовпець):
    ч = pd.to_numeric(df[стовпець], errors='coerce').dropna()
    return ч[ч > 0]

def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    if ш in ('ідентифікатор',):
        return р

    if ш == 'номінальна':
        р['мода'] = з.mode().iloc[0]
        р['частоти'] = з.value_counts().head(3).to_dict()
        return р

    if ш == 'порядкова':
        з = з.map(очистити_кт)
        р['унікальних після очищення'] = з.nunique()
        р['мода'] = з.mode().iloc[0]
        р['частоти'] = з.value_counts().to_dict()
        к = pd.Categorical(з, categories=ПОРЯДОК_КТ, ordered=True).codes
        к = pd.Series(к)
        р['медіана'] = ПОРЯДОК_КТ[int(к.median())]
        р['квантилі 25/75'] = (ПОРЯДОК_КТ[int(к.quantile(.25))], ПОРЯДОК_
        return р

    if ш == 'інтервальна':
        д = pd.to_datetime(df[стовпець], errors='coerce').dropna()
        р['мода'] = д.mode().iloc[0].date()
        р['медіана'] = д.median().date()
        р['середнє'] = д.mean().date()
        р['ст. відхилення, днів'] = round(д.std().days + д.std().seconds
        return р

    if стовпець == 'АТ стац':
        ат = df[стовпець].dropna().astype(str).str.strip().str.split('/',
        ат.columns = ['систолічний', 'діастолічний']
        for к in ат:
            р[к] = {'мода': ат[к].mode().iloc[0], 'медіана': ат[к].median
                    'середнє': round(ат[к].mean(), 1), 'ст. відхилення':
                    'коеф. варіації': round(ат[к].std() / ат[к].mean(), 3
        return р
```

```
    ч = числа(стовпець)
    p['мода'] = ч.mode().iloc[0]
    p['частоти'] = ч.value_counts().head(3).to_dict()
    p['медіана'] = ч.median()
    p['квантилі 25/75'] = (ч.quantile(.25), ч.quantile(.75))
    p['середнє'] = round(ч.mean(), 2)
    p['ст. відхилення'] = round(ч.std(), 2)
    p['коеф. варіації'] = round(ч.std() / ч.mean(), 3)
    return p


for c in МОЇ:
    print(f'--- {c}  ({ПАСПОРТ[c][0]})')
    print('   ', допустима_статистика(c, ПАСПОРТ[c][0]))
    print()
```

```
--- Телефон  (ідентифікатор)
    {'непорожніх': 120, 'унікальних': 120}

--- Примітка  (номінальна)
    {'непорожніх': 45, 'унікальних': 44, 'мода': 'Поліалергетик', 'частот
и': {'Поліалергетик': 2, 'отримував актемра, часті носові кровотечі, втрат
а нюху': 1, 'часта втрата свідомості в стаціонарі': 1}}

--- ступінь КТ  (порядкова)
    {'непорожніх': 42, 'унікальних': 12, 'унікальних після очищення': 5,
'мода': 'середній', 'частоти': {'середній': 18, 'важкий': 10, 'легкий': 7,
'вкрай важкий': 4, 'критичний': 3}, 'медіана': 'середній', 'квантилі 25/7
5': ('середній', 'важкий')}

--- Виписка  (інтервальна)
    {'непорожніх': 120, 'унікальних': 90, 'мода': datetime.date(2021, 9,
7), 'медіана': datetime.date(2022, 3, 15), 'середнє': datetime.date(2022,
1, 29), 'ст. відхилення, днів': 109.5}

--- spO2 випис  (відношень)
    {'непорожніх': 68, 'унікальних': 11, 'мода': np.float64(97.0), 'частот
и': {97.0: 12, 96.0: 11, 98.0: 9}, 'медіана': np.float64(96.0), 'квантилі
25/75': (np.float64(94.0), np.float64(97.0)), 'середнє': np.float64(95.7),
'ст. відхилення': np.float64(1.8), 'коеф. варіації': np.float64(0.019)}

--- АТ стац  (відношень)
    {'непорожніх': 120, 'унікальних': 21, 'систолічний': {'мода': np.float
64(130.0), 'медіана': np.float64(130.0), 'середнє': np.float64(130.7), 'с
т. відхилення': np.float64(11.5), 'коеф. варіації': np.float64(0.088)}, 'д
іастолічний': {'мода': np.float64(80.0), 'медіана': np.float64(80.0), 'сер
еднє': np.float64(82.1), 'ст. відхилення': np.float64(7.8), 'коеф. варіаці
ї': np.float64(0.095)}}

--- Д-дим2  (відношень)
    {'непорожніх': 30, 'унікальних': 30, 'мода': np.float64(0.25), 'частот
и': {744.0: 1, 1370.0: 1, 276.0: 1}, 'медіана': np.float64(1063.0), 'квант
илі 25/75': (np.float64(531.0), np.float64(2546.0)), 'середнє': np.float64
(1786.2), 'ст. відхилення': np.float64(1729.93), 'коеф. варіації': np.floa
t64(0.968)}

--- Гемогл2  (відношень)
    {'непорожніх': 105, 'унікальних': 60, 'мода': np.float64(142.0), 'част
оти': {144.0: 5, 142.0: 5, 137.0: 4}, 'медіана': np.float64(134.0), 'квант
илі 25/75': (np.float64(116.0), np.float64(144.0)), 'середнє': np.float64
(128.71), 'ст. відхилення': np.float64(23.51), 'коеф. варіації': np.float6
4(0.183)}
```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

In [9]:
```
df[МОЇ].describe(include='all').T
```

Out[9]:

	count	unique	top	freq
Телефон	120	120	0958469788 дружина Ганна	1
Примітка	45	44	Поліалергетик	2
ступінь КТ	42	12	середній	10
Виписка	120	90	2021-11-19 00:00:00	3
spO2 випис	68	11	97	12
АТ стац	120	21	130/80	63
Д-дим2	30	30	744	1
Гемогл2	105	60	144	5

In [10]:
```
ТЕЛ = pd.to_numeric(df['Телефон'], errors='coerce').dropna()
КОДИ_КТ = df['ступінь КТ'].dropna().map(очистити_кт).map({н: і for і, н і
ДАТИ = pd.to_datetime(df['Виписка'], errors='coerce').dropna()
ДНІ = (ДАТИ - pd.Timestamp('1970-01-01')).dt.days

БЕЗГЛУЗДІ = [
    ('Телефон', 'середнє', round(ТЕЛ.mean()),
     'Телефон — ідентифікатор: середнє номерів телефонів не відповідає жо
    ('ступінь КТ', 'середнє кодів', round(КОДИ_КТ.mean(), 2),
     'Ступінь — порядкова шкала: коди 0–4 задають лише порядок, відстані
    ('Виписка', 'коефіцієнт варіації', round(ДНІ.std() / ДНІ.mean(), 4),
     'Дата — інтервальна шкала: нуль відліку умовний (1970 р.), тож відно
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення', 'Ч
```

Out[10]:

	Стовпець	Статистика	Значення	Чому безглузде
0	Телефон	середнє	7.587990e+08	Телефон — ідентифікатор: середнє номерів телефонів не відповідає жодній величині.
1	ступінь КТ	середнє кодів	1.480000e+00	Ступінь — порядкова шкала: коди 0–4 задають лише порядок, відстані між ступенями невідомі, середнє не має змісту.
2	Виписка	коефіцієнт варіації	5.800000e-03	Дата — інтервальна шкала: нуль відліку умовний (1970 р.), тож відношення std/mean залежить від вибору початку й не має змісту.

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

In [11]:
```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or '(ви
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or '(ви
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: ЛН × помер/жив

ЛН: шкала — не у вашому списку
помер/жив: шкала — не у вашому списку

       ЛН  помер/жив
0  III-IV          1
1  II-III          2
2      II          2
3  III-IV          2
4  II-III          2
5  II-III          1
```

In [12]:
```
from scipy.stats import chi2_contingency

ОБРАНА_МІРА = 'Коефіцієнт Крамера (V) та χ²'
ЧОМУ_САМЕ_ВОНА = 'ЛН — порядкова шкала, помер/жив — бінарна номінальна; д

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

таблиця = pd.crosstab(df[A], df[B])
print(таблиця)
print()
xi2, p, ст_вільн, очік = chi2_contingency(таблиця)
n = таблиця.values.sum()
V = np.sqrt(xi2 / (n * (min(таблиця.shape) - 1)))
print(f'χ² = {xi2:.2f}, ст. вільності = {ст_вільн}, p = {p:.2e}')
print(f'V Крамера = {V:.3f}')
print(f'Клітинок із очікуваною частотою < 5: {(очік < 5).sum()} з {очік.s
print()
print('Зв’язок сильний: V = %.2f. Усі пацієнти зі ступенем I, I-II та II
print('а за ступеня II-III померли 49 із 59.')
```

```
помер/жив   1   2
ЛН
I           0  12
I-II        0   9
II          0  21
II-III     49  10
III        11   6
III-IV      1   2

χ² = 69.58, ст. вільності = 5, p = 1.25e-13
V Крамера = 0.758
Клітинок із очікуваною частотою < 5: 4 з 12

Зв’язок сильний: V = 0.76. Усі пацієнти зі ступенем I, I-II та II вижили,
а за ступеня II-III померли 49 із 59.
```

In [13]:
```
alf = df[A].astype('category').cat.codes
інший = df[A].map({'III': 0, 'I': 1, 'II-III': 2, 'III-IV': 3, 'I-II': 4,

print('Пірсон між ЛН і помер/жив:')
print('  коди за алфавітом   :', round(alf.corr(df[B]), 3))
print('  коди в іншому порядку:', round(інший.corr(df[B]), 3))
print()
print('Знак і величина r змінюються разом із довільним порядком кодів ЛН,
print('а помер/жив — номінальна змінна. Пірсон припускає числові шкали')
print('з рівними інтервалами, тому отримане число інтерпретувати не можна
```

```
Пірсон між ЛН і помер/жив:
  коди за алфавітом   : -0.544
  коди в іншому порядку: 0.424

Знак і величина r змінюються разом із довільним порядком кодів ЛН,
а помер/жив — номінальна змінна. Пірсон припускає числові шкали
з рівними інтервалами, тому отримане число інтерпретувати не можна.
```

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

In [14]:
```
ПІДГОТОВКА = {
    'Телефон':    'Ідентифікатор: у модель не беремо взагалі.',
    'Примітка':   'Вільний текст: у модель не беремо; можливі окремі біна
    'ступінь КТ': 'Очищення написань і впорядкована категорія легкий < се
    'Виписка':    'Дата: перехід до тривалості перебування в днях (Виписк
    'spO2 випис': 'Нулі замінити пропусками, далі стандартизація або норм
    'АТ стац':    'Розбити на систолічний і діастолічний тиск, далі станд
    'Д-дим2':     'Привести значення до однієї одиниці, далі логарифмуван
    'Гемогл2':    'Текст «немає» замінити пропуском, далі стандартизація.
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

Out[14]:

	Стовпець	Шкала	Як готуємо
0	Телефон	ідентифікатор	Ідентифікатор: у модель не беремо взагалі.
1	Примітка	номінальна	Вільний текст: у модель не беремо; можливі окремі бінарні ознаки за ключовими словами.
2	ступінь КТ	порядкова	Очищення написань і впорядкована категорія легкий < середній < важкий < вкрай важкий < критичний.
3	Виписка	інтервальна	Дата: перехід до тривалості перебування в днях (Виписка − Поступлення), далі стандартизація.
4	spO2 випис	відношень	Нулі замінити пропусками, далі стандартизація або нормалізація.
5	АТ стац	відношень	Розбити на систолічний і діастолічний тиск, далі стандартизація кожного.
6	Д-дим2	відношень	Привести значення до однієї одиниці, далі логарифмування й стандартизація.
7	Гемогл2	відношень	Текст «немає» замінити пропуском, далі стандартизація.

In [15]:
```
# порядкова: ступінь КТ
кт_порядок = pd.Categorical(df['ступінь КТ'].dropna().map(очистити_кт),
                            categories=ПОРЯДОК_КТ, ordered=True)
print('ступінь КТ:', pd.Series(кт_порядок.codes).value_counts().sort_inde

# інтервальна: тривалість перебування замість дати
тривалість = (pd.to_datetime(df['Виписка'], errors='coerce')
              - pd.to_datetime(df['Поступлення'], errors='coerce')).dt.da
тривалість = тривалість.where(тривалість >= 0)
тривалість_z = (тривалість - тривалість.mean()) / тривалість.std()
print('Тривалість, днів: середнє %.1f, std %.1f' % (тривалість.mean(), тр
print('Стандартизована: середнє %.2f, std %.2f' % (тривалість_z.mean(), т

# відношень: гемоглобін
гемогл = pd.to_numeric(df['Гемогл2'], errors='coerce')
assert гемогл.nunique() > 1
гемогл_z = (гемогл - гемогл.mean()) / гемогл.std()
print('Гемогл2 стандартизований: середнє %.2f, std %.2f' % (гемогл_z.mean
```

```
ступінь КТ: {0: 7, 1: 18, 2: 10, 3: 4, 4: 3}
Тривалість, днів: середнє 19.6, std 20.9
Стандартизована: середнє -0.00, std 1.00
Гемогл2 стандартизований: середнє 0.00, std 1.00
```

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний `NaN` замість помилки.

In [16]:
```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення
    elif len(з) and з.max() == з.min():
```

```
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

In [17]:
```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`**. Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

In [18]:
```
ВИПРАВЛЕННЯ = [
    (1, 'Номінальна шкала: помер/жив закодовано 1 і 2, і від нього обчисл
        'Коди 1 і 2 — лише мітки категорій, тому середнє 1.50 не означає
        'Подати частоти: 61 помер (50.4%) і 60 вижили (49.6%); мода — «по
    (2, 'Дані не придатні: одна ознака записана різними написаннями, тому
        'Значення «ж» і «жін», «ч» і «чол» позначають одне й те саме, тож
        'Об’єднати написання й порахувати частоти: ж — 75 (62%), ч — 46 (
    (3, 'Порядкова шкала: від ступеня обчислено середнє кодів; категорії
        'Коди задають лише порядок, відстаней між ступенями немає; сортув
        'Очистити назви, задати порядок легкий < … < критичний; обчислити
    (4, 'Дані не придатні: у КТ частина значень записана текстом-діапазон
        'Через errors=\'coerce\' діапазони стали пропусками, середнє пора
        'Перетворити діапазони на числа (наприклад, середина діапазону) а
    (5, 'Дані не придатні: у spO2 є значення 0.9, імовірно, ввели не у ві
        'Мінімум 0.9% фізіологічно неможливий для живого пацієнта, він зн
        'Виправити або виключити значення 0.9, повідомляти медіану (84) р
    (6, 'Інтервальна шкала: коефіцієнт варіації обчислено для дат.',
        'Нуль дат умовний (1970 р.), тому CV залежить від початку відліку
        'Описувати потік розмахом і стандартним відхиленням у днях (розма
    (7, 'Номінальна шкала: кореляцію Пірсона застосовано до двох закодова
        'Коди 0/1 для статі не мають числового змісту; Пірсон показує лиш
        'Таблиця спряженості, χ² і коефіцієнт Крамера V (V = 0.18, p ≈ 0.
    (8, 'Номінальні та сталі стовпці включено до min-max нормалізації.',
        'Нормалізовано також помер/жив (категоріальний код), а ФЕРИТ2 має
        'Нормалізувати лише змістовно числові стовпці з nunique > 1; кате
    (9, 'Дані не придатні: dropna() видаляє всі рядки, бо в кожному рядку
        'Після видалення залишилось 0 рядків із 121, тож «повністю заповн
        'Видалити стовпці з надмірною кількістю пропусків і обрати відпов
```

```
    (10, 'Витік цільової змінної: дата розтину існує лише для померлих.',
         'r = 1.00 означає, що ознака відома лише після результату; крім
         'Виключити «Дата розтину» з предикторів і ранжувати лише ознаки,
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із 1
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть усі
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення зако

pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число неп
```

Out[18]:

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1	Номінальна шкала: помер/жив закодовано 1 і 2, і від нього обчислено середнє.	Коди 1 і 2 — лише мітки категорій, тому середнє 1.50 не означає «посередині між результатами» і не має змісту.	Подати частоти: 61 помер (50.4%) і 60 вижили (49.6%); мода — «помер».
1	2	Дані не придатні: одна ознака записана різними написаннями, тому «статей» нараховано чотири.	Значення «ж» і «жін», «ч» і «чол» позначають одне й те саме, тож статей дві, а не чотири.	Об'єднати написання й порахувати частоти: ж — 75 (62%), ч — 46 (38%).
2	3	Порядкова шкала: від ступеня обчислено середнє кодів; категорії ще й записані по-різному.	Коди задають лише порядок, відстаней між ступенями немає; сортування за алфавітом ламає порядок, а варіанти написання дублюють категорії.	Очистити назви, задати порядок легкий < ... < критичний; обчислити медіану й моду (мода та медіана — «середній»).
3	4	Дані не придатні: у КТ частина значень записана текстом-діапазоном («20-30%», «до 17%»).	Через errors='coerce' діапазони стали пропусками, середнє пораховано лише за 27 з 44 заповнених значень і не відображає вибірку.	Перетворити діапазони на числа (наприклад, середина діапазону) або вказати, що показник визначений лише для 27 пацієнтів.
4	5	Дані не придатні: у spO2 є значення 0.9, імовірно, ввели не у відсотках; воно спотворює мінімум і середнє.	Мінімум 0.9% фізіологічно неможливий для живого пацієнта, він знижує середнє 82.73 до 82.05; висновок про «виражену недостатність» спирається на помилковий запис.	Виправити або виключити значення 0.9, повідомляти медіану (84) разом із розкидом.
5	6	Інтервальна шкала: коефіцієнт варіації обчислено для дат.	Нуль дат умовний (1970 р.), тому CV залежить від початку відліку; значення менше 1% говорить лише про великі числа днів від епохи.	Описувати потік розмахом і стандартним відхиленням у днях (розмах 463 дні) або кількістю госпіталізацій за місяць.
6	7	Номінальна шкала: кореляцію Пірсона застосовано до двох закодованих	Коди 0/1 для статі не мають числового змісту; Пірсон показує лише лінійну залежність між числами, а «r близьке до	Таблиця спряженості, χ^2 і коефіцієнт Крамера V (V = 0.18, p ≈ 0.05); висновок

Розділ		Що не так	Чому число неправильне	Як правильно
		номінальних змінних.	нуля» хибне: r = 0.18, p = 0.052.	«зв’язку немає» не обґрунтований.
7	8	Номінальні та сталі стовпці включено до min-max нормалізації.	Нормалізовано також помер/жив (категоріальний код), а ФЕРИТ2 має одне значення, тому max − min = 0 і ділення на нуль дає NaN.	Нормалізувати лише змістовно числові стовпці з nunique > 1; категоріальні кодувати окремо, сталі виключити.
8	9	Дані не придатні: dropna() видаляє всі рядки, бо в кожному рядку є хоча б один пропуск.	Після видалення залишилось 0 рядків із 121, тож «повністю заповнений набір» порожній; пропуски часто структурні (дата розтину є лише в померлих).	Видалити стовпці з надмірною кількістю пропусків і обрати відповідну імпутацію, пропуски в Дата розтину не імпутувати.
9	10	Витік цільової змінної: дата розтину існує лише для померлих.	r = 1.00 означає, що ознака відома лише після результату; крім того, NaT перетворено на велике від’ємне число і кореляцію обчислено на неіснуючих значеннях.	Виключити «Дата розтину» з предикторів і ранжувати лише ознаки, відомі до результату (наприклад, Лім2, ІЛ6-2, Вік).

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [19]:
```
# розділ 3: ступінь КТ
сирі = df['ступінь КТ'].dropna()
чисті = pd.Categorical(сирі.map(очистити_кт), categories=ПОРЯДОК_КТ, orde
коди = pd.Series(чисті.codes)
print('Розділ 3. Неправильно: середній код =', round(коди.mean(), 2))
print('Розділ 3. Правильно: мода =', pd.Series(чисті).mode()[0], '| медіа
print(pd.Series(чисті).value_counts().sort_index().to_string())
print()

# розділ 6: дати
дати = pd.to_datetime(df['Поступлення'], errors='coerce').dropna()
print('Розділ 6. Неправильно: CV дат =', round(100 * (дати.astype('int64'
print('Розділ 6. Правильно: розмах =', (дати.max() - дати.min()).days, 'д
      'std =', round(дати.std().days + дати.std().seconds / 86400, 1), 'д
print()

# розділ 9: пропуски
print('Розділ 9. Неправильно: рядків після dropna() =', len(df.dropna()))
пропуски = df.isna().mean().sort_values(ascending=False)
print('Розділ 9. Правильно: стовпців з >50% пропусків:', int((пропуски >
```

```
залишок = df.loc[:, пропуски <= .5].dropna(how='any', subset=['Вік', 'пом
print('Після видалення таких стовпців рядків із заповненими Вік і помер/ж
```

```
Розділ 3. Неправильно: середній код = 1.48
Розділ 3. Правильно: мода = середній | медіана = середній
легкий           7
середній        18
важкий          10
вкрай важкий     4
критичний        3

Розділ 6. Неправильно: CV дат = 0.595 %
Розділ 6. Правильно: розмах = 463 днів; std = 113.0 днів

Розділ 9. Неправильно: рядків після dropna() = 0
Розділ 9. Правильно: стовпців з >50% пропусків: 11 з 77
Після видалення таких стовпців рядків із заповненими Вік і помер/жив: 121
```

Етап 7. Висновки та індивідуальне питання

In [20]:
```
ВИСНОВКИ = [
    'Тяжкість легеневої недостатності (ЛН) сильно пов’язана з результатом
    'У моєму наборі Телефон є ідентифікатором, ступінь КТ порядковою шкал
    'Багато стовпців потребують очищення перед аналізом: у ступені КТ два
]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for і, в in enumerate(ВИСНОВКИ, 1):
    print(f'{і}. {в}')
```

```
1. Тяжкість легеневої недостатності (ЛН) сильно пов’язана з результатом лі
кування: V Крамера становить 0.76, а всі 42 пацієнти зі ступенями I, I-II
та II вижили.
2. У моєму наборі Телефон є ідентифікатором, ступінь КТ порядковою шкалою,
дата виписки інтервальною, а тиск, Д-димер, гемоглобін і сатурація — шкало
ю відношень, тож середнє коректне лише для останніх чотирьох і для дат.
3. Багато стовпців потребують очищення перед аналізом: у ступені КТ дванад
цять написань п’яти категорій, у spO2 при виписці є 10 нулів, а в Д-димері
змішані одиниці вимірювання.
```

In [21]:
```
print('ВАШЕ ПИТАННЯ:'); print(В['питання']); print()
ВІДПОВІДЬ = (
    'Значення «АТ пост» — рядок, у якому записано два вимірювання: систол
    'Перший спосіб: розбити рядок на два числові стовпці, САТ і ДАТ. '
    'Другий спосіб: обчислити похідні величини — пульсовий тиск (САТ − ДА
    'Третій спосіб: віднести пацієнта до категорії за порогами тиску (нор
    'У модель я візьму перший спосіб: САТ і ДАТ зберігають усю початкову
    'не вводять довільних порогів, як категорії, а похідні величини при п
)
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою (ві
print(ВІДПОВІДЬ)
```

```
ВАШЕ ПИТАННЯ:
Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте три
способи перетворити його на числові ознаки та обґрунтуйте, який із них віз
ьмете в модель.

Значення «АТ пост» — рядок, у якому записано два вимірювання: систолічний
і діастолічний тиск. Перший спосіб: розбити рядок на два числові стовпці,
САТ і ДАТ. Другий спосіб: обчислити похідні величини — пульсовий тиск (САТ
– ДАТ) або середній артеріальний тиск (ДАТ + (САТ – ДАТ)/3). Третій спосі
б: віднести пацієнта до категорії за порогами тиску (норма, гіпертензія I,
II, III ступеня), тобто перетворити на порядкову ознаку. У модель я візьму
перший спосіб: САТ і ДАТ зберігають усю початкову інформацію, лишаються у
шкалі відношень (мм рт. ст.), не вводять довільних порогів, як категорії,
а похідні величини при потребі можна отримати з них самих.
```

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті
- `'текст, як є'` — згенерований текст залишено майже без змін

In [22]:
```python
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':        'текст, як є',
    'етап 2 — допустимі статистики':   'код, перевірено',
    'етап 3 — безглузді числа':        'код, перевірено',
    'етап 4 — міра зв’язку':           'код, перевірено',
    'етап 5 — підготовка до моделі':   'код, перевірено',
    'етап 6 — виправлення аналізу':    'код, перевірено',
    'етап 7 — висновки й відповідь':   'текст, як є',
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = 'Я запустила ноутбук згори донизу без помилок. Пере
```

```
ПІДТВЕРДЖУЮ = True      # я можу пояснити кожен рядок свого коду
                        # і внести в нього зміни на вимогу під час захист
```

In [23]:

```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено

перевірки = {
    'заповнено титульні поля':        bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМ
    'етап 1: паспорт із 8 стовпців':  all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1]
    'етап 3: три безглузді числа':    len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and len(ЧОМУ_САМЕ_
    'етап 5: підготовку описано':     all(len(ПІДГОТОВКА[c].strip()) >= 1
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':           len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':   len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':           all(v in ФОРМУЛЮВАННЯ for v in ДЕКЛ
    'опис перевірки ≥ 120 символів':  len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >=
    'підтвердження авторства':        ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-лис
print()
print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
====================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  ГОТОВО     опис перевірки ≥ 120 символів
  ГОТОВО     підтвердження авторства
====================================================

Робота варіанта 12 готова до захисту.
Хвостова Олександра, ШІ-32
```

Перед здачею

Виконайте **Kernel** → **Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.